ИИ-ассистент системы стабилизации «Поток-М»: концепт

Октябрь 2026

Abstract

Статья описывает, каким мы видим бортовой ИИ-ассистент для системы стабилизации ракеты «Поток-М». Небольшая нейросеть (1–5 млн параметров) читает окно бортовых датчиков и подстраивает уставки классического контура. Решение о поправке и право отключения остаются за детерминированным кодом. Дальше — обоснование стека (линейное внимание, спектральные низкоранговые слои TSCT, тернарные факторы, 4-битные активации, оптимизатор Muon), схема обучения на собственном симуляторе, правила безопасности и план проверки: симулятор, стенд, лётные пуски.

Keywords бортовой искусственный интеллект · активная стабилизация · тернарная квантизация · низкоранговое сжатие · оптимизатор Muon

1 Введение

«Поток-М» — двухступенчатая ракета на твёрдотопливных двигателях. Масса около 13 кг, проектная высота порядка 3 км, скорость до 240 м/с, а статический запас устойчивости всего около 0,957 калибра. Запас маленький, и резкая турбулентность легко уводит ракету с траектории: порывы бокового ветра дают снос в сотни метров, при сильной турбулентности — в тысячи.

ПИД-регулятор держит ракету, пока динамика близка к расчётной, а порыв — редкое событие с большой амплитудой, и под него трудно настроиться: быстрый контур дёргает ракету в спокойном воздухе, медленный не успевает за порывом. Нейросеть может заметить порыв в окне показаний раньше, чем он проявится в отклонении. Примеры есть: нейросетевой автопилот испытан в полёте (Koch и др. 2019), а обучаемые модели гасили ветер до 12 м/с на малой авиации (O'Connell и др. 2022).

Мы закладываем ИИ как ассистента, а не как замену. Управляет по-прежнему код, сеть лишь предлагает поправку, которую код вправе отклонить. Ассистента можно выключить целиком, и от этого ничего не ломается.

2 Концепт гибридного контура

Пусть $u_{\mathrm{PID}(t)}$ — команда классического регулятора, g_θ — выход нейросети по окну датчиков длины T (0,5–1 с). Суммарная команда:

$$u(t) = u_{\mathrm{PID}(t)} + \alpha(t) g_\theta(x_{t-T..t}), \quad \alpha(t) \in [0,1], \quad |g_\theta| \le G_{\max} \tag{1}$$

Коэффициент доверия α задаёт степень участия сети, при $\alpha = 0$ ассистент выключен полностью. Выход сети ограничен по амплитуде и по фазе полёта, а каждая поправка проходит через валидатор: он сверяет её с моделью полёта. Если проверка не проходит, ассистент отключается до конца полёта и дальше работает чистая классика. Отключиться безопасно: без ассистента остаётся ровно тот контур, который летал бы и без него.

На вход идёт весь набор бортовых измерений: температура, давление, высота, кажущиеся скорости и ускорения по трём осям, угловые скорости гироскопа. Классический контур работает на частоте 200–400 Гц, ассистент — асинхронно, 50–100 Гц. Его выход: поправка уставок тангажа и рыскания либо оценка ветра. Дополнительно сеть следит за телеметрией и подмечает аномалии, но решения о спасении остаются за классическим кодом.

3 Компактный стек для борта

Бюджет такой: параметров не больше пяти миллионов, инференс 50–100 Гц на микроконтроллере семейства STM32 с внешней энергонезависимой памятью. Стек не гипотеза: спектральные низкоранговые слои, квантизацию их факторов и Muon мы отработали на компактных языковых моделях. В задаче стабилизации меняется только вход: вместо текста — окно сенсоров. За латентность отвечает внимание, за память вместе с числом параметров — квантизация и низкий ранг, а Muon нужен на обучении.

3.1 Линейное внимание

Базовая архитектура — трансформер с линейным вниманием класса KDA (Kimi Team 2025) (гейтированное дельта-правило). Состояние фиксированного размера, поэтому стоимость вывода не растёт с длиной окна; полное квадратичное внимание на борту не нужно. Достаточно 2–4 слоёв ширины 128–256. Последовательность кадров датчиков — это поток векторов, «язык телеметрии»; модель предобучается на нём теми же приёмами, что языковые модели.

3.2 Спектральные низкоранговые слои (TSCT)

Широкие линейные слои мы параметризуем низкоранговой спектральной формой — это наша технология TSCT:

$$W \approx U \cdot \mathrm{diag}(s) \cdot V^{\top}, \quad r(n_{\mathrm{in}} + n_{\mathrm{out}} + 1) \le n_{\mathrm{in}} n_{\mathrm{out}} \tag{2}$$

Параметров становится $r(n_{\mathrm{in}} + n_{\mathrm{out}} + 1)$ вместо $n_{\mathrm{in}} n_{\mathrm{out}}$: проекция 256→1024 при ранге 32 занимает около 41 тыс. вместо 262 тыс. Раз в несколько шагов факторы проходят полярную ретракцию (итерации Ньютона–Шульца) и возвращаются на ортонормальную поверхность; это численная устойчивость при агрессивной квантизации. Похожие методы сжимают уже обученную сеть разовой SVD (Yuan и др. 2023), у нас факторизация обучается с нуля.

3.3 Тернарные факторы и 4-битные активации

Квантизуются не плотные веса, а сами факторы разложения. Каждый элемент U и V хранится тернарно, со значениями $\{-\alpha_w, 0, +\alpha_w\}$ и масштабом $\alpha_w = \mathrm{mean}\,|W|$ (схема b1.58 (Ma и др. 2024)):

$$\widetilde{W} = \alpha_w \cdot \mathrm{RoundClip}\left(\frac{W}{\alpha_w + \varepsilon}, -1, 1\right) \tag{3}$$

Память — около 1,58 бита на элемент фактора: та же проекция 256→1024 при ранге 32 занимает 8 КБ вместо 512 КБ в fp16. Тернарные модели держат качество и на малых размерах, если удвоить ширину слоёв (Nielsen и Schneider-Kamp 2024), а движки низкобитного вывода ускоряют и энергосберегают вычисления в разы (Wang и др. 2024; Wei и др. 2024). Активации мы предлагаем квантовать до 4 бит по схеме BitNet v2 (Wang и др. 2025): перед квантизацией к ним применяется быстрое преобразование Адамара, которое сглаживает выбросы. Из-за выбросов низкобитные активации обычно и ломаются.

3.4 Оптимизатор

Обучение ведёт Muon (Liu и др. 2025). Импульс ортогонализуется полиномами Ньютона–Шульца, затем нормируется по строкам и столбцам (ColRow):

$$O_t = \mathrm{ColRow}\big(\mathrm{orth}_{\mathrm{NS}(M_t)}\big), \quad W_t = W_{t-1} - \eta O_t \tag{4}$$

На трансформерах Muon примерно вдвое эффективнее AdamW и не расшатывается на длинных прогонах (Liu и др. 2025). Данных у нас мало, поэтому важна цена в шагах до рабочего качества.

Компонент	**Что даёт**	**Эффект для борта**
Линейное внимание	вывод $O(1)$ по окну	латентность не растёт с окном
Спектральные слои (TSCT)	$r(n_{\mathrm{in}} + n_{\mathrm{out}} + 1)$ параметров	в разы меньше параметров
Тернарные факторы, 4-бит активации	1,58 бита на элемент	5 млн параметров — около 1 МБ
Muon	ортогонализованный шаг	меньше шагов обучения

Таблица 1. Компоненты стека и их вклад в бюджет бортовой модели

4 Обучение

4.1 Данные: собственный симулятор

Лётных данных мало, единицы пусков, поэтому основу даёт собственный симулятор. Модель: жёсткое тело переменной массы с шестью степенями свободы, тяга по измеренному профилю, аэродинамика по таблицам коэффициентов, стандартная атмосфера, турбулентность по модели Драйдена и отдельные порывы. Сенсорный тракт моделируется отдельно: шум, квантование, задержки, частоты. Сеть должна видеть ту же телеметрию, что и борт. Масса, центровка, тяга и ветер рандомизируются в пределах допусков, иначе модель выучит идеальный симулятор вместо ракеты. Датасет — порядка 10^5 эпизодов по 30 с, а цели для обучения берём у эталонного оффлайн-оптимизатора, который решает ту же задачу на полной модели.

4.2 Схема обучения

Обучение идёт в три этапа. Сначала предобучение без разметки: кадры сенсоров маскируются и предсказываются, так строятся представления «языка телеметрии». Затем

дистилляция: сеть воспроизводит коррекцию эталона, а лосс, кроме ошибки коррекции, получает штраф за высокочастотное дёрганье выхода, потому что команды должны быть гладкими. На третьем этапе, если понадобится, добавляется RL-доводка со штрафами за выход за безопасные пределы. Уже после дистилляции ассистент можно включать при малом α, а доверие наращивать по замерам. Проверка идёт на отложенных сценариях, которых не было в обучении: другие профили ветра, массы, задержки. Метрики — интегральная ошибка траектории и перерегулирование, сравнение всегда с чистым ПИД-контуром.

5 Безопасность

Риск ассистента ограничен четырьмя правилами. Спасением сеть не управляет: разделение ступеней, парашюты и таймеры остаются на классической логике. Выход ограничен по амплитуде и скорости изменения, а если ответ не пришёл за 10–20 мс, ассистент отключается до конца полёта. Модель в полёте заморожена: только инференс, никакого дообучения. Данные с зависших или вышедших из диапазона датчиков отбрасываются до входа в сеть. Телеметрия и все вмешательства пишутся в журнал, чтобы после полёта можно было разобрать каждое решение.

6 Верификация и перспективы

План проверки: симулятор (сравнение с ПИД-эталоном), затем стенд (прошивка на реальной плате, записанные потоки, замер латентности и памяти), затем лётные пуски, не менее двух по регламенту изделия. Цели концепта — не более 5 млн параметров и 10–20 мс, итог фиксируем замерами. Новизна в том, что публичных примеров тернарных сетей в реальном времени в контуре управления мы не нашли: известные нейро-контуры полноточные (Koch и др. 2019; O'Connell и др. 2022). Тот же стек пригодится и дальше: управляемый спуск, другие носители, наземная робототехника.

7 Заключение

К классической стабилизации «Поток-М» добавляется компактный ИИ-ассистент. Линейное внимание, TSCT, тернарные факторы и 4-битные активации, Muon — всё это укладывается в 1–5 млн параметров и считается на бортовом микроконтроллере. Главным остаётся классический код, а ассистента можно выключить. Дальше — симулятор, стенд, пуски.

Библиография

[1] W. Koch, R. Mancuso, и A. Bestavros, «Neuroflight: Next Generation Flight Control Firmware», *arXiv preprint arXiv:1901.06553*, 2019.

[2] M. O'Connell *и др.*, «Neural-Fly Enables Rapid Learning for Agile Flight in Strong Winds», *arXiv preprint arXiv:2205.06908*, 2022.

[3] Kimi Team, «Kimi Linear: An Expressive, Efficient Attention Architecture», *arXiv preprint arXiv:2510.26692*, 2025.

[4] Z. Yuan *и др.*, «ASVD: Activation-aware Singular Value Decomposition for Compressing Large Language Models», *arXiv preprint arXiv:2312.05821*, 2023.

[5] S. Ma *и др.*, «The Era of 1-bit LLMs: All Large Language Models are in 1.58 Bits», *arXiv preprint arXiv:2402.17764*, 2024.

[6] J. Nielsen и P. Schneider-Kamp, «BitNet b1.58 Reloaded: State-of-the-art Performance Also on Smaller Networks», *arXiv preprint arXiv:2407.09527*, 2024.

[7] J. Wang *и др.*, «1-bit AI Infra: Part 1.1, Fast and Lossless BitNet b1.58 Inference on CPUs», *arXiv preprint arXiv:2410.16144*, 2024.

[8] J. Wei *и др.*, «T-MAC: CPU Renaissance via Table Lookup for Low-Bit LLM Deployment on Edge», *arXiv preprint arXiv:2407.00088*, 2024.

[9] H. Wang, S. Ma, и F. Wei, «BitNet v2: Native 4-bit Activations with Hadamard Transformation for 1-bit LLMs», *arXiv preprint arXiv:2504.18415*, 2025.

[10] J. Liu *и др.*, «Muon is Scalable for LLM Training», *arXiv preprint arXiv:2502.16982*, 2025.